

Progetto di Classificazione delle Immagini con TensorFlow e Keras

Sergio Cucinotta

9 settembre 2024

1 Abstract

L'obiettivo del test è di sviluppare un modello di machine learning che possa classificare automaticamente se un'immagine contiene un cane o un gatto, raggiungendo il 90% di accuracy. Per restare coerente all'obiettivo definito, e non essendo chiara la presenza o meno di altre specie nel dataset, ho sviluppato il progetto concentrandolo sulla distinzione tra cani e gatti all'interno di un dataset contenente queste due specie.

Il modello ottimizzato ha mostrato un'accuratezza del 93% nel riconoscere con successo le immagini di entrambe le categorie. La metodologia include un'attenta pre-elaborazione dei dati, la progettazione di un'architettura CNN con accorgimenti anti-overfitting e una valutazione dettagliata delle prestazioni sul dataset di test separato.

2 Analisi e pre-elaborazione dei Dati

Il dataset iniziale conteneva un totale di 25.000 immagini, suddivise equamente tra cani e gatti.

Durante l'analisi preliminare, è stato individuato un gruppo di 1.578 immagini corrotte, che sono state rimosse per assicurare l'integrità e la qualità del dataset.

Successivamente, le immagini sono state ridimensionate a 128x128 pixel per ridurre il carico computazionale e migliorare le prestazioni. Il dataset è stato diviso in set di addestramento (80%, 18.560 immagini), set di validazione (20%, 4.640 immagini) e set di test (200 immagini), sempre suddivise equamente tra cani e gatti.

```
1 new_img_size = (128,128)
2 data_split = 0.2
3 batch_size = 64
4 seed_value = 42
5
6 train_ds = tf.keras.preprocessing.image_dataset_from_directory(
```

```

7     pets_images,
8     validation_split=data_split,
9     subset="training",
10    seed=seed_value,
11    image_size=new_img_size,
12    batch_size=batch_size)
13
14 val_ds = tf.keras.preprocessing.image_dataset_from_directory(
15     pets_images,
16     validation_split=data_split,
17     subset="validation",
18     seed=seed_value,
19     image_size=new_img_size,
20     batch_size=batch_size)
21
22 test_ds = tf.keras.preprocessing.image_dataset_from_directory(
23     test_images,
24     seed=seed_value,
25     image_size=new_img_size,
26     batch_size=batch_size)

```

Questa fase di preparazione dei dati è stata essenziale per garantire una solida base di immagini bilanciate e di alta qualità su cui addestrare e valutare il modello di riconoscimento.

3 Sviluppo e valutazione del Modello

Il modello implementato è un classificatore sequenziale di reti neurali convoluzionali (CNN). È composto da diversi strati che svolgono diverse operazioni, come convoluzioni, normalizzazione, max pooling e Dropout, seguiti da strati densi.

3.1 Modello Iniziale

```

1 model = Sequential()
2
3 model.add(Conv2D(8, (3,3), activation='relu', kernel_initializer='
4     he_uniform', padding='same'))
5 model.add(layers.BatchNormalization())
6 model.add(MaxPooling2D(2,2))
7 model.add(layers.Dropout(0.2))
8
9 model.add(Conv2D(16, (3,3), activation='relu', kernel_initializer='
10     he_uniform', padding='same'))
11 model.add(layers.BatchNormalization())
12 model.add(MaxPooling2D(2,2))
13 model.add(layers.Dropout(0.2))
14
15 model.add(Conv2D(32, (3,3), activation='relu', kernel_initializer='
16     he_uniform', padding='same'))
17 model.add(layers.BatchNormalization())
18 model.add(MaxPooling2D(2,2))
19 model.add(layers.Dropout(0.2))

```

```

17 model.add(Flatten())
18 model.add(Dense(128, activation='relu', kernel_initializer='
19     he_uniform'))
20 model.add(Dense(1, activation='sigmoid'))
21
22 model.compile(optimizer=Adam(learning_rate=0.001), loss='
23     binary_crossentropy', metrics=['acc'])
24 history = model.fit(train_ds, validation_data = val_ds, epochs = 20 )

```

Il primo modello implementato è composto da tre strati convoluzionali: il primo strato convoluzionale ha 8 filtri 3x3, il secondo 16 e il terzo 32, sempre 3x3, e ognuno di essi è accompagnato da normalizzazione, MaxPooling2d e Dropout.

Dopodiché l'output dei layer convoluzionali viene convertito in un vettore piatto e si passa per due strati densi: il primo comprende 128 neuroni con attivazione ReLU, mentre il secondo ha un singolo neurone di output con attivazione sigmoide per la classificazione binaria (cane o gatto).

Per l'addestramento, il modello è stato compilato con l'ottimizzatore Adam, utilizzando un tasso di apprendimento di 0.001 e una funzione di loss `binary_crossentropy`. L'addestramento del modello è stato eseguito per 20 epoche.

Nonostante l'architettura del modello abbia mostrato una buona capacità di apprendimento iniziale, sono state evidenziate alcune chiare problematiche di overfitting.




Figura 1: Perdita/Accuratezza di Allenamento e Validazione per Epoca - Primo Modello

Il valore della loss sul set di addestramento è notevolmente inferiore a quello del set di validazione. Ciò potrebbe indicare che il modello stia memorizzando i dati di addestramento senza generalizzare bene su nuovi dati. L'accuratezza sul set di addestramento è invece notevolmente maggiore rispetto a quella sul set di validazione. Ad esempio, l'accuratezza di addestramento è arrivata fino a circa il 97%, mentre quella di validazione è rimasta intorno al 80%.

Entrambi i grafici mostrano quindi un andamento molto diverso tra i set di addestramento e validazione, causato appunto da un evidente situazione di overfitting.

3.2 Ottimizzazione del modello

```
1 model = Sequential()
2
3 model.add(Conv2D(16, (3,3), activation='relu', kernel_initializer='
    he_uniform', padding='same'))
4 model.add(layers.BatchNormalization())
5 model.add(MaxPooling2D(2,2))
6 model.add(layers.Dropout(0.2))
7
8 model.add(Conv2D(32, (3,3), activation='relu', kernel_initializer='
    he_uniform', padding='same'))
9 model.add(layers.BatchNormalization())
10 model.add(MaxPooling2D(2,2))
11 model.add(layers.Dropout(0.2))
12
13 model.add(Conv2D(32, (3,3), activation='relu', kernel_initializer='
    he_uniform', padding='same'))
14 model.add(layers.BatchNormalization())
15 model.add(MaxPooling2D(2,2))
16 model.add(layers.Dropout(0.2))
17
18 model.add(Conv2D(64, (3,3), activation='relu', kernel_initializer='
    he_uniform', padding='same'))
19 model.add(layers.BatchNormalization())
20 model.add(MaxPooling2D(2,2))
21 model.add(layers.Dropout(0.2))
22
23 model.add(Conv2D(256, (3,3), activation='relu', kernel_initializer='
    he_uniform', padding='same'))
24 model.add(layers.BatchNormalization())
25 model.add(MaxPooling2D(2,2))
26 model.add(layers.Dropout(0.2))
27
28 model.add(Flatten())
29 model.add(Dense(256, activation='relu', kernel_initializer='
    he_uniform'))
30 model.add(layers.Dropout(0.3))
31 model.add(layers.BatchNormalization())
32 model.add(Dense(1, activation='sigmoid'))
33
34 model.compile(optimizer=Adam(learning_rate=0.001), loss='
    binary_crossentropy', metrics=['acc'])
35 history = model.fit(train_ds, validation_data = val_ds, epochs = 25 )
```

Il secondo modello è più profondo e complesso. Utilizza cinque strati convoluzionali con un numero crescente di filtri (16, 32, 32, 64, 256) per catturare e apprendere dettagli gerarchici di diversi livelli di astrazione nelle immagini. L'introduzione di una maggiore profondità e complessità nel modello può consentire una migliore estrazione delle caratteristiche distintive delle immagini, fornendo al modello una maggiore capacità di apprendimento e generalizzazione.

Inoltre, nel secondo modello è stata aggiunta una maggiore regolarizzazione con l'uso di un layer dropout più intenso (con un valore del 30%) e l'inclusione di strati aggiuntivi di normalizzazione BatchNormalization. Questi accorgimen-

ti aiutano a ridurre ulteriormente l'overfitting e a migliorare la capacità del modello di generalizzare su dati non visti durante l'addestramento.

Dopo 15 epoche, il modello ha già raggiunto un'accuratezza di circa il 92.17% sul set di addestramento e del 90.11% sul set di validazione.

```

1 Epoch 1/25
2 290/290 [=====] - 80s 269ms/step - loss:
   0.6493 - acc: 0.6546 - val_loss: 0.6265 - val_acc: 0.6640
3 Epoch 2/25
4 290/290 [=====] - 79s 270ms/step - loss:
   0.5175 - acc: 0.7457 - val_loss: 0.6588 - val_acc: 0.7259
5 Epoch 3/25
6 290/290 [=====] - 79s 270ms/step - loss:
   0.4584 - acc: 0.7830 - val_loss: 0.5049 - val_acc: 0.7603
7 Epoch 4/25
8 290/290 [=====] - 79s 271ms/step - loss:
   0.4110 - acc: 0.8105 - val_loss: 0.5494 - val_acc: 0.7457
9 Epoch 5/25
10 290/290 [=====] - 79s 272ms/step - loss:
   0.3784 - acc: 0.8270 - val_loss: 0.4082 - val_acc: 0.8162
11 Epoch 6/25
12 290/290 [=====] - 81s 277ms/step - loss:
   0.3492 - acc: 0.8452 - val_loss: 0.4305 - val_acc: 0.8009
13 Epoch 7/25
14 290/290 [=====] - 79s 272ms/step - loss:
   0.3212 - acc: 0.8624 - val_loss: 0.3663 - val_acc: 0.8416
15 Epoch 8/25
16 290/290 [=====] - 81s 280ms/step - loss:
   0.3002 - acc: 0.8688 - val_loss: 0.3460 - val_acc: 0.8502
17 Epoch 9/25
18 290/290 [=====] - 83s 284ms/step - loss:
   0.2834 - acc: 0.8782 - val_loss: 0.3275 - val_acc: 0.8532
19 Epoch 10/25
20 290/290 [=====] - 79s 273ms/step - loss:
   0.2612 - acc: 0.8876 - val_loss: 0.3183 - val_acc: 0.8597
21 Epoch 11/25
22 290/290 [=====] - 76s 262ms/step - loss:
   0.2380 - acc: 0.9022 - val_loss: 0.2992 - val_acc: 0.8711
23 Epoch 12/25
24 290/290 [=====] - 76s 262ms/step - loss:
   0.2276 - acc: 0.9030 - val_loss: 0.2965 - val_acc: 0.8763
25 Epoch 13/25
26 290/290 [=====] - 76s 262ms/step - loss:
   0.2154 - acc: 0.9091 - val_loss: 0.2600 - val_acc: 0.8877
27 Epoch 14/25
28 290/290 [=====] - 79s 271ms/step - loss:
   0.2014 - acc: 0.9148 - val_loss: 0.2946 - val_acc: 0.8733
29 Epoch 15/25
30 290/290 [=====] - 78s 267ms/step - loss:
   0.1906 - acc: 0.9217 - val_loss: 0.2428 - val_acc: 0.9011
31 Epoch 16/25
32 290/290 [=====] - 80s 275ms/step - loss:
   0.1773 - acc: 0.9276 - val_loss: 0.3691 - val_acc: 0.8584
33 Epoch 17/25
34 290/290 [=====] - 80s 276ms/step - loss:
   0.1658 - acc: 0.9325 - val_loss: 0.2610 - val_acc: 0.8938
35 Epoch 18/25

```

```

36 290/290 [=====] - 79s 270ms/step - loss:
    0.1605 - acc: 0.9346 - val_loss: 0.2711 - val_acc: 0.9002
37 Epoch 19/25
38 290/290 [=====] - 78s 270ms/step - loss:
    0.1502 - acc: 0.9386 - val_loss: 0.2561 - val_acc: 0.9028
39 Epoch 20/25
40 290/290 [=====] - 80s 275ms/step - loss:
    0.1384 - acc: 0.9442 - val_loss: 0.2646 - val_acc: 0.9011
41 Epoch 21/25
42 290/290 [=====] - 80s 276ms/step - loss:
    0.1328 - acc: 0.9481 - val_loss: 0.2671 - val_acc: 0.9011
43 Epoch 22/25
44 290/290 [=====] - 82s 281ms/step - loss:
    0.1230 - acc: 0.9505 - val_loss: 0.2901 - val_acc: 0.8912
45 Epoch 23/25
46 290/290 [=====] - 84s 290ms/step - loss:
    0.1153 - acc: 0.9543 - val_loss: 0.3207 - val_acc: 0.8851
47 Epoch 24/25
48 290/290 [=====] - 82s 283ms/step - loss:
    0.1126 - acc: 0.9569 - val_loss: 0.2686 - val_acc: 0.9024
49 Epoch 25/25
50 290/290 [=====] - 81s 280ms/step - loss:
    0.1070 - acc: 0.9593 - val_loss: 0.2637 - val_acc: 0.9060

```




Figura 2: Perdita/Accuratezza di Allenamento e Validazione per Epoca - Secondo modello

Entrambi i grafici mostrano un buon andamento generale, con perdite decrescenti e aumenti di accuratezza nelle epoche successive. Si può notare un leggero divario tra le performance sui set di addestramento e validazione, suggerendo una potenziale leggera sovrapposizione e un livello minimo di overfitting.

4 Valutazione e risultati del modello

```

1 import numpy as np
2
3 y_pred = []
4 y_true = []
5
6 for images, labels in test_ds:

```

```

7     predictions = model.predict(images)
8     y_pred.extend(predictions)
9     y_true.extend(labels.numpy())
10
11 y_pred = np.array(y_pred).reshape(-1)
12 y_true = np.array(y_true)
13 y_pred_classes = np.where(y_pred < 0.5, 0, 1)
14
15 from sklearn.metrics import classification_report
16
17 print(classification_report(y_true, y_pred_classes))

```

Quest'ultima parte di codice esegue l'analisi delle prestazioni sul dataset di test del modello addestrato. Vengono effettuate previsioni sul dataset di test e valutate le performance del modello confrontando le previsioni con le etichette reali.

La funzione `classification_report` di `sklearn` fornisce una valutazione dettagliata delle metriche di precisione, richiamo e F1-score.

L'output mostra che il modello ha ottenuto un'accuratezza complessiva del 93%. Tale valutazione è supportata da metriche bilanciate di precisione e richiamo per entrambe le classi, indicando una buona capacità del modello nel riconoscere sia i cani che i gatti all'interno del dataset di test.

```

1 2/2 [=====] - 0s 33ms/step
2 2/2 [=====] - 0s 31ms/step
3 2/2 [=====] - 0s 30ms/step
4 1/1 [=====] - 0s 153ms/step
5
6           precision    recall  f1-score   support
7
8          0           0.92       0.93       0.93         100
9          1           0.93       0.92       0.92         100
10
11   accuracy                    0.93         200
11   macro avg           0.93       0.93       0.92         200
12   weighted avg           0.93       0.93       0.92         200

```